

Министерство науки и высшего образования Российской Федерации
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ ЯДЕРНЫЙ УНИВЕРСИТЕТ
«МИФИ»

ИНСТИТУТ ЛАЗЕРНЫХ И ПЛАЗМЕННЫХ ТЕХНОЛОГИЙ
КАФЕДРА №31 ПРИКЛАДНАЯ МАТЕМАТИКА

ОТЧЕТ

по научно-исследовательской работе
за весенний семестр 2025 года

на тему:

Использование алгоритмов машинного обучения
для предсказания развития интракраниальной прогрессии

Авторы:

Соколов Владимир,
Поздняков Владимир
Группа: Б23-205

г. Москва 2025

Содержание

1	Точная постановка задачи	5
2	Используемые алгоритмы	6
2.1	К-ближайших соседей (KNN)	6
2.2	Дерево решений (Decision Tree)	7
2.3	Метод опорных векторов (SVM)	8
2.4	Логистическая регрессия (Logistic Regression)	9
2.5	Случайный лес (Random Forest)	9
3	Обработка данных	10
3.1	Обработка пропусков в колонках	11
3.2	One-Hot Encoding	12
3.3	Обработка дат	13
3.4	Матрица корреляции	13
3.5	Нормализация данных	14
3.6	Балансировка данных	16
3.6.1	Random Oversampling	16
3.6.2	SMOTE	17
4	Выбор метрик эффективности	17
5	Интерпретация полученных результатов	18
5.1	Несбалансированные данные	19
5.2	Random Oversampling	22
5.3	SMOTE	25

Аннотация

В данной работе проводилось исследование пяти алгоритмов машинного обучения. Для этого были подготовлены данные и выбраны метрики эффективности алгоритмов. Для более подробного анализа была проведена интерпретация результатов с использованием LIME и SHAP.

Введение

Метастатические опухоли головного мозга — вторичные злокачественные образования, возникающие в центральной нервной системе в результате распространения раковых клеток из первичной опухоли других органов. Это осложнение значительно ухудшает прогноз заболевания.

Исследования, проведенные в мемориальном онкологическом центре имени Слоуна-Кеттеринга, показали, что наиболее часто метастазы в мозг дают рак лёгких (48% случаев), опухоли молочной железы (15%), меланома (9%) и колоректальный рак (3%) [1]. Клинические проявления зависят от количества, размера и расположения метастазов, а также от степени воздействия на окружающие мозговые структуры.

Основными методами лечения являются лучевая терапия (включая стереотаксическую радиохирургию), химиотерапия, таргетная терапия и, в отдельных случаях, хирургическое удаление метастатических очагов.

В работе проведено исследование выбранных алгоритмов машинного обучения, предсказывающих прогрессию опухоли головного мозга. В качестве исходных данных использовалась выборка из 585 пациентов. Были выбраны два наиболее эффективных алгоритма, для которых производился последующий анализ.

- В *разделе 1* приведена точная формулировка задачи.
- В *разделе 2* выбраны алгоритмы машинного обучения и приведено их описание.
- В *разделе 3* описан процесс обработки исходных данных для последующей работы.
- В *разделе 4* приведено описание некоторых метрик эффективности алгоритмов и выбраны наиболее подходящие для дальнейшего исследования.
- В *разделе 5* проведено сравнение полученных результатов. Для двух лучших моделей произведена интерпретация результатов с использованием LIME и SHAP.

1 Точная постановка задачи

Имеется выборка пациентов, включающая такие данные, как онкологический диагноз, даты проведения операций, виды лечения и другие признаки необходимые для исследования. Требуется исследовать важность признаков пациента при предсказании развития метастазов головного мозга. Для решения задачи необходимо сравнить эффективность различных алгоритмов машинного обучения и использовать наиболее эффективные алгоритмы на тестовой выборке.

2 Используемые алгоритмы

В этом разделе приведено описание пяти алгоритмов машинного обучения, используемых для проведения исследования.

2.1 К-ближайших соседей (KNN)

К-ближайших соседей (KNN) — это алгоритм машинного обучения с учителем, который обычно используется для классификации, но также может применяться для задач регрессии.

Он работает по принципу поиска k ближайших точек данных (соседей) для заданного входного значения и делает предсказания на основе большинства классов (для классификации) или среднего значения (для регрессии).

Алгоритм строится следующим образом:

- 1) сначала вычисляется расстояние между тестовым и всеми обучающими образцами;
- 2) далее из них выбирается k -ближайших образцов (соседей), где число k задаётся заранее;
- 3) итоговым прогнозом среди выбранных k -ближайших образцов будет мода в случае классификации и среднее арифметическое в случае регрессии;
- 4) предыдущие шаги повторяются для всех тестовых образцов.

Допустим, есть набор данных с двумя классами, при этом пространство признаков двумерное с признаками x и y . Новая точка должна быть классифицирована. Сначала вычисляются расстояния до всех точек. Далее выбираются k ближайших соседей. Далее алгоритм анализирует их классы. Если среди соседей больше точек первого класса, то новая точка относится к первому классу. Если больше точек второго класса, новая точка относится к второму классу. На Рис. 1 приведена иллюстрация описанного метода.




Рис. 1: Принцип работы KNN

2.2 Дерево решений (Decision Tree)

Дерево решений — это алгоритм машинного обучения, используемый для задач классификации и регрессии. Он строит иерархическую структуру правил вида «если-то», разбивая данные на подмножества, пока не будет достигнут прогнозируемый результат. Алгоритм строит бинарное дерево, начиная с корневого узла, и рекурсивно разделяет данные на подгруппы, выбирая наилучшие признаки для разбиения.

На каждом шаге алгоритм оценивает возможные способы разделения данных, используя критерии информативности. Для классификации используется энтропия (мера неопределенности) или индекс Джини (мера неоднородности).

Из построения лерева решений следует иерархия признаков. Признаки, помещённые ближе к корневому узлу, имеют решающее значений. При этом короткие пути в дереве означают наличие признаков, по которым можно определить наличие интракраниальной прогрессии у пациента за небольшое количество сравнений. На Рис. 2 показан пример дерева решений.




Рис. 2: Дерево решений

2.3 Метод опорных векторов (SVM)

Ключевая идея алгоритма SVM заключается в нахождении гиперплоскости, которая наилучшим образом разделяет два класса, максимизируя зазор между ними. Этот зазор представляет собой расстояние от гиперплоскости до ближайших точек данных (называемых опорными векторами) с каждой из сторон.

Когда данные не являются линейно разделимыми, метод опорных векторов использует ядро. Этот подход преобразует исходные данные таким образом, чтобы они стали разделимыми нелинейной границей. Ядро — это функция, которая неявно отображает данные в пространство более высокой размерности, избегая сложных вычислений координат в этом пространстве. На Рис. 3 приведена иллюстрация метода опорных векторов.




Рис. 3: Несколько гиперплоскостей, разделяющие два класса

2.4 Логистическая регрессия (Logistic Regression)

Логистическая регрессия — это алгоритм машинного обучения с учителем, используемый для задач классификации, где цель состоит в том, чтобы предсказать вероятность того, что экземпляр принадлежит к заданному классу или нет.

Логистическая регрессия используется для бинарной классификации, где используется сигмоидальная функция, которая принимает входные данные в качестве независимых переменных и принимает значения вероятности от 0 до 1.

Модель оптимизируется по методу максимального правдоподобия, чтобы найти оптимальную область разграничения между классами. Эта функция измеряет разницу между предсказанными вероятностями и фактическими классами. Пусть $h_\theta(x_i)$ - предсказанная вероятность, что $y_i = 1$, моделью с параметрами θ . Формула логистической ошибки выглядит следующим образом:

$$L(\theta) = -\frac{1}{n} \sum_{i=1}^n [y_i \log(h_\theta(x_i)) + (1 - y_i) \log(1 - h_\theta(x_i))] \quad (1)$$

2.5 Случайный лес (Random Forest)

Метод случайного леса строится на основе ансамбля деревьев решений. Основная идея заключается в том, чтобы создать множество деревьев решений и объединить их результаты для получения более точного прогноза. Сначала создается случайная подвыборка из исходного набора данных, далее для каждой подвыборки строится дерево решений. Итоговый прогноз получается в результате агрегирования ответов множества деревьев. Для задачи классификации используется голосование большинства, а для задачи регрессии — усреднение предсказаний всех деревьев. На Рис. 4 приведена иллюстрация данного алгоритма.




Рис. 4: Случайный лес

3 Обработка данных

Дана таблица, включающая в себя информацию о 866 пациентах. Исходная таблица имеет следующие колонки:

1. Пол (М/Ж);
2. Дата Рождения;
3. Онкологический диагноз (пять типов):
 - РМЖ — рак молочной железы;
 - РП — рак почки;
 - Меланома — рак кожи;
 - НМРЛ — немелкоклеточный рак лёгкого;
 - КРР — колоректальный рак.
4. Дата постановки диагноза;
5. Дата удаления первичного очага;
6. Дата развития метастаз головного мозга;

7. Активирующие мутации;
8. Дата проведения облучения всего головного мозга (если проводилось);
9. Дата операции на головном мозге;
10. Число фракций стереотаксической радиотерапии (число облучений очагов в головном мозге);
11. Дата первой стереотаксической радиотерапии;
12. Индекс Карновского;
13. Число очагов в головном мозге;
14. Суммарный объём очагов;
15. Объём максимального очага;
16. Экстракраниальные метастазы;
17. Лекарственное лечение (три варианта):
 - Химиотерапия;
 - Таргетная терапия;
 - Без лечения.
18. Локальный рецидив (нет либо дата обнаружения);
19. Дистантные метастазы (нет либо дата обнаружения);
20. Интракраниальная прогрессия

3.1 Обработка пропусков в колонках

В исходных данных колонки «Локальный рецидив», «Дистантные метастазы» и «Интракраниальная прогрессия» являются целевыми, поэтому требуется удалить строки с пропущенными данными в этих колонках. Также отметим, что выбранные алгоритмы машинного обучения будут предсказывать только наличие прогрессии опухолей у пациентов, не различая вид прогрессии. Для этого требуется на основе указанных колонок создать новую колонку «Прогрессия», содержащую бинарную

целевую переменную (1, если у пациента наблюдался любой вид метастаз головного мозга, и 0 в противном случае).

Также нужно удалить колонки, в которых достаточно много пропусков (более 20%), так как они малоинформативны. На Рис. 5 приведена столбчатая диаграмма, иллюстрирующая количество пропусков в процентах от количества пациентов.




Рис. 5: Процент пропусков в исходных данных

Столбцы «Активирующие мутации», «Экскраниальные метастазы», «Дата удаления первичного очага» содержат много пропусков поэтому их придется удалить. Столбец «Лекарственное лечение» содержит категориальные данные, а значит к этим данным будет применен метод *One-Hot Encoding*, позволяющий перевести данные в численный тип. Будет создано несколько колонок, а значит количество пропусков в каждой из новых колонок будет допустимым. Подробнее этот метод описан в следующем подразделе.

3.2 One-Hot Encoding

Кроме столбца «Лекарственное лечение» в исходных данных есть столбец «Онкологический диагноз», содержащий категориальные данные. Для преобразования этих данных в численные применим метод *One-Hot Encoding*.

Данный тип кодирования, основывается на создании бинарных признаков, которые показывают принадлежность к уникальному значению. В рассматриваемой задаче столбец «Онкологический диагноз» преобразуется в пять бинарных столбцов «РМЖ», «РП», «НМРЛ», «Меланома» и «КРР». Столбец «Лекарственное лечение»

преобразуется в три бинарных столбца «Химиотерапия», «Таргетная терапия» и «Без лечения».

3.3 Обработка дат

Чтобы не работать с датами напрямую, столбцы с датами следует преобразовать в столбцы, содержащие разность дат (т.е. время в днях, прошедшее между двумя событиями). Сформируем три новые колонки: «1-ая СРТ - ДР» (возраст пациента на момент первой радиотерапии), «1-ая СРТ - Развитие МГМ» (время между первой радиотерапией и развитием метастаз) и «Развитие МГМ - Постановка онкологического диагноза» (время между развитием метастаз и постановкой онкологического диагноза). Отметим, что последние два столбца могут содержать отрицательные значения в отличие от первого.

3.4 Матрица корреляции

Все исходные данные приведены к численному типу, поэтому по новым данным можно построить корреляционную матрицу. Корреляционная матрица позволит узнать зависимость признаков и удалить линейно зависимые признаки. Это важно сделать, так как алгоритмы машинного обучения предполагают независимость данных в выборке.

На Рис. 6 приведена корреляционная матрица, на которой заметна сильная корреляция между признаками «Макс. объем очага» и «Объем очагов». Один из них нужно удалить, в нашем случае был удален столбец «Макс. объем очага».




Рис. 6: Корреляционная матрица

3.5 Нормализация данных

Нормализация — это метод предобработки данных, при котором числовые признаки приводятся к общему стандартному диапазону, чтобы обеспечить равный вклад всех характеристик в обучение модели. Исходные данные содержат достаточно много выбросов, как на Рис. 7, поэтому требуется нормализовать данные перед использованием алгоритмов машинного обучения.




Рис. 7: Иллюстрация выбросов на примере распределения суммарного объема очагов

Для центрирования использовалось медианное значение и коэффициент масштабирования, предложенный в статье «An Adjusted Boxplot for Skewed Distributions». Ниже приведено описание метода.

Пусть X — выборка, а x_m — медианное значение. Введем множества $X^+ = \{x \in X \mid x \leq x_m\}$ и $X^- = \{x \in X \mid x \geq x_m\}$. Для $x^+ \in X^+$ и $x^- \in X^-$. Определим функцию:

$$h(x^-, x^+) = \begin{cases} \frac{(x^+ - x_m) - (x_m - x^-)}{x^+ - x^-}, & x^- < x^+, \\ 0, & x^- = x^+ = x_m. \end{cases} \quad (2)$$

Тогда коэффициент асимметрии MC будет вычислять как медиана множества $\{h(x^-, x^+) \mid x^- \in X^- \wedge x^+ \in X^+\}$. Пусть Q_1, Q_3 - первый и третий квартили множества X соответственно. Теперь определим доверительный интервал:

$$AdjInt = \begin{cases} [Q_1 - 1.5e^{-4MC}(Q_3 - Q_1), Q_3 + 1.5e^{3MC}(Q_3 - Q_1)], & MC \geq 0, \\ [Q_1 - 1.5e^{-3MC}(Q_3 - Q_1), Q_3 + 1.5e^{4MC}(Q_3 - Q_1)], & MC < 0. \end{cases} \quad (3)$$

Коэффициент масштабирования σ вычисляется следующим образом:

$$\sigma = \max\{x \in X \mid x \in AdjInt\} - \min\{x \in X \mid x \in AdjInt\} \quad (4)$$

Для каждого значения $x \in X$ вычисляется нормализованное значение $\hat{x}$:

$$\hat{x} = \frac{x - x_m}{\sigma} \quad (5)$$

3.6 Балансировка данных

На Рис. 8 приведена столбчатая диаграмма, иллюстрирующая количество пациентов из выборки с прогрессией опухолей и без. По этой диаграмме заметен дисбаланс между классами. Это негативно сказывается на предсказательной способности некоторых алгоритмов, поэтому требуется предварительная балансировка данных. В этом подразделе приведено описание двух методов балансировки данных, используемых в данной работе.




Рис. 8: Дисбаланс классов

3.6.1 Random Oversampling

Random oversampling — это метод обработки данных, который увеличивает количество экземпляров в классе с меньшим представительством путём случайного дублирования образцов из этого класса.

Отличительной особенностью данного метода является сохранение информации. При дублировании данных из класса-меньшинства не создается никаких новых экземпляров.

3.6.2 SMOTE

При использовании метода *SMOTE* (*Synthetic Minority Oversampling Technique*) создаются новые образцы для класса-меньшинства на основании уже существующих.

SMOTE начинает с выбора случайного образца из меньшинства класса. Для каждого образца алгоритм находит K ближайших соседей в пространстве признаков. Это значение K обычно задается пользователем (часто $K=5$). Случайно выбирается один из K ближайших соседей.

Создается синтетический образец, который находится на линии, соединяющей выбранный образец и его случайно выбранного соседа. Пусть x_i - исходный образец, x_j - выбранный сосед, а δ - случайное число из отрезка $[0, 1]$. Тогда синтетический образец x^* создается по формуле:

$$x^* = x_i + (x_j - x_i) \cdot \delta \quad (6)$$

4 Выбор метрик эффективности

Перед рассмотрением основных метрик для оценки точности используемых алгоритмов введем основные понятия:

- TP (True Positive) — количество истинно-положительных объектов;
- FP (False Positive) — количество ложно-положительных объектов;
- TN (True Negative) — количество истинно-отрицательных объектов;
- FN (False Negative) — количество ложно-отрицательных объектов.

Положительным объектом будем называть объект, который относится к классу 1 (у пациента наблюдалась прогрессия), отрицательным — объект класса 0 (у пациента нет прогрессии). Если объект истинно-, то алгоритм правильно определил класс, если ложно-, то не правильно.

Определим значения точности (precision) и полноты (recall):

$$Precision = \frac{TP}{TP + FP} \quad (7)$$

$$Recall = \frac{TP}{TP + FN} \quad (8)$$

Ниже приведены три метрики, которые использовались в данной работе при анализе точности рассматриваемых алгоритмов.

$$F_1 = \frac{2 \cdot Precision \cdot Recall}{Precision + Recall} \quad (9)$$

F_1 — это гармоническое среднее между точностью и полнотой. Используется, когда важно учитывать оба показателя, особенно при дисбалансе классов.

$$balanced_accuracy = \frac{1}{2} \left(\frac{TP}{TP + FN} + \frac{TN}{FP + TN} \right) \quad (10)$$

Метрика $balanced_accuracy$ используется при дисбалансе классов и учитывает все предсказания алгоритма, минимизируя оба типа ошибок.

$$F_\beta = (1 + \beta^2) \frac{Precision \cdot Recall}{\beta^2 \cdot Precision + Recall} \quad (11)$$

Обобщение F_1 , где параметр β задаёт важность полноты относительно точности. При исследовании использовалось значение $\beta = 2$.

5 Интерпретация полученных результатов

Для оценки важности признаков будем использовать методы SHAP и LIME. Оба метода позволяют интерпретировать полученные результаты и объяснить вклад каждого признака в предсказание конкретного наблюдения.

SHAP (SHapley Additive exPlanations) представляет собой формальный метод объяснения предсказаний машинного обучения, основанный на концепции значений Шепли из теории кооперативных игр. Данный подход количественно оценивает маргинальный вклад каждого признака в выходное значение модели, обеспечивая как локальную интерпретацию отдельных предсказаний, так и глобальную интерпретацию поведения модели в целом..

LIME (Local Interpretable Model-agnostic Explanations) реализует принципиально иной подход к интерпретации, основанный на локальной аппроксимации сложной модели простой интерпретируемой моделью в окрестности конкретной точки данных. Метод генерирует пертурбации исходного примера, анализирует соответствующие изменения в предсказаниях исходной модели и строит локально адекватное объяснение.

В то время как SHAP предлагает теоретически обоснованную, но вычислительно сложную процедуру объяснения, LIME обеспечивает более эффективную, но ограниченную локальным контекстом интерпретацию. Использование этих подходов позволяет получить комплексное представление о поведении модели на различных уровнях абстракции.

В следующих подразделах указаны таблицы с метриками для рассматриваемых моделей. Важно отметить, что для метрики F_β использовалось значение $\beta = 2$. Пациенты с метастазами не должны быть пропущены, поэтому важно следить за значениями FN и отсеивать модели с высокими показателями. Выбор между оставшимися алгоритмами производится на основании метрик эффективности алгоритмов. Таким образом для каждого случая находится компромисс между снижением FN и увеличением показателей метрик и определяются две наилучшие модели.

5.1 Несбалансированные данные

Для каждого алгоритма были получены оценки точности с использованием описанных ранее метрик. На Рис. 9 приведены полученные результаты для несбалансированных данных.

	Models	balanced_accuracy	f1_accuracy	fbeta_accuracy	FN
0	KNN	0.526829	0.777778	0.738397	12
1	Support vectors machine (SVM)	0.483798	0.797927	0.731939	5
2	Decision Tree	0.577875	0.788571	0.759912	13
3	Logistic Regression	0.590244	0.766467	0.758294	18
4	Random Forest	0.606620	0.760736	0.763547	20

Рис. 9: Результаты обучения для несбалансированных данных

Наилучшими алгоритмами для несбалансированных данных оказались модели «Logistic Regression» и «Decision Tree». Заметна достаточно низкая точность, но в то же время небольшие значения FN . Это связано с тем, что классификаторы могут «подстраиваться» под класс большинства при дисбалансе классов. На рисунках ниже приведены результаты, полученные с использованием методом SHAP и LIME.

Logistic Regression LIME explanation	
Feature	Weight
Число фракций СРТ ≤ 0.00	-0.2583
КРР ≤ 0.00	0.0929
Операция ≤ 0.00	-0.0811
Меланома ≤ 0.00	-0.0808
$0.00 < \text{Таргентная терапия} \leq 1.00$	0.0639
Число очагов в ГМ ≤ -0.08	-0.0633
Индекс Карновского ≤ -0.17	-0.0530
РП > 0.00	0.0518
Пол ≤ 0.00	-0.0454
РМЖ ≤ 0.00	0.0440

Рис. 10: LIME интерпретация для Logistic Regression

Decision Tree LIME explanation	
Признак	Вклад
НМРЛ ≤ 0.00	0.1118
ОВГМ ≤ 0.00	-0.0896
Индекс Карновского ≤ -0.17	-0.0587
Операция ≤ 0.00	-0.0471
РП > 0.00	0.0460
Меланома ≤ 0.00	-0.0382
Число очагов в ГМ ≤ -0.08	-0.0224
РМЖ ≤ 0.00	0.0216
Число фракций СРТ ≤ 0.00	-0.0197
$-0.06 < \text{Суммарный объем очагов} \leq 0.01$	-0.0191

Рис. 11: LIME интерпретация для Decision Tree




Рис. 12: SHAP интерпретация для Logistic Regression




Рис. 13: SHAP интерпретация для Decision Tree

Оказалось, что «Число фракций СРТ» является наиболее важным признаком при обучении моделей. Причем по скоплению точек в правой полуплоскости для этого признака можно сделать вывод, что увеличение количества сеансов лучевой терапии улучшает прогноз. Однако для алгоритма «Decision Tree» важность этого призна-

ка немного снижена. Также признаки «Пол», «Число очагов в ГМ» и «1-ая СРТ - ДР» (возраст пациента на момент лечения) имеют положительную корреляцию с вероятностью прогрессии. Для признака «Операция» получился ожидаемый результат. Положительные значения Шепли свидетельствуют об улучшении прогноза при наличии хирургического вмешательства. Для признака «1-ая СРТ - ДР» также получилась логичная закономерность. При уменьшении возраста пациента значения Шепли также уменьшаются, то есть возраст может быть менее значимым фактором для молодых пациентов в отличие от других признаков.

5.2 Random Oversampling

На Рис. 14 приведены полученные результаты для данных после балансировки повторным использованием данных (Random Oversampling).

	Models	balanced_accuracy	f1_accuracy	fbeta_accuracy	FN
0	KNN	0.639373	0.748387	0.775401	24
1	Support vectors machine (SVM)	0.614808	0.757764	0.766332	21
2	Decision Tree	0.629094	0.762500	0.774112	21
3	Logistic Regression	0.545296	0.763006	0.739910	16
4	Random Forest	0.645296	0.795181	0.789474	16

Рис. 14: Результаты обучения для данных после балансировки Random Oversampling

Лучшими моделями оказались «Decision Tree» и «Random Forest». Балансировка данных помогает моделям лучше распознавать миноритарный класс, но приводит к росту FN . Рост FN происходит за счет повторения экземпляров класса-меньшинства. Также наблюдается рост $balanced_accuracy$, что говорит о том, что алгоритмы стали лучше предсказывать оба класса (и мажоритарный, и миноритарный). На рисунках ниже приведены результаты, полученные с использованием методом SHAP и LIME.

Decision Tree LIME explanation	
Признак	Вклад
Число фракций СРТ ≤ 0.00	-0.5056
Число очагов в ГМ ≤ -0.08	-0.0540
ОВГМ ≤ 0.00	0.0500
$-0.12 < 1\text{-ая СРТ} - \text{ДР} \leq 0.00$	0.0473
РП > 0.00	0.0470
1-ая СРТ - Развитие МГМ > 0.06	-0.0466
НМРЛ ≤ 0.00	-0.0360
КРР ≤ 0.00	0.0325
$-0.06 < \text{Суммарный объем очагов} \leq 0.00$	-0.0275
$0.00 < \text{Экстракраниальные метастазы} \leq 1.00$	0.0238

Рис. 15: LIME интерпретация для Decision Tree

Random Forest LIME explanation	
Feature	Weight
Число фракций СРТ ≤ 0.00	-0.3757
Число очагов в ГМ ≤ -0.08	-0.0637
КРР ≤ 0.00	0.0549
Операция ≤ 0.00	-0.0471
1-ая СРТ - Развитие МГМ > 0.06	-0.0440
ОВГМ ≤ 0.00	-0.0320
Меланома ≤ 0.00	-0.0305
$-0.06 < \text{Суммарный объем очагов} \leq 0.00$	-0.0228
Индекс Карновского ≤ -0.17	-0.0206
НМРЛ ≤ 0.00	0.0185

Рис. 16: LIME интерпретация для Random Forest




Рис. 17: SHAP интерпретация для Decision Tree




Рис. 18: SHAP интерпретация для Random Forest

После балансировки оба класса учитываются равномерно, поэтому влияние признаков более предсказуемо. Так, например, пропадает ложное влияние признака «Пол». Снова наблюдается важность признаков «Число фракций СРТ» и «Число очагов в ГМ». Для сбалансированных данных признак «1-ая СРТ - ДР» (возраст пациента на момент лечения) также оказывает большое влияние на прогноз алгоритмов. При увеличении возраста пациента увеличиваются значения Шепли. Это свидетельствует о том, что модели чаще учитывают возраст как фактор риска. Интервал между развитием метастаз головного мозга и 1-ой СРТ начинает оказывать большое влияние после балансировки исходных данных. По графикам видно, что

признак «1-ая СРТ - Развитие МГМ» и вероятность прогрессии имеют обратную зависимость.

5.3 SMOTE

На Рис. 19 приведены полученные результаты для данных после балансировки SMOTE.

	Models	balanced_accuracy	f1_accuracy	fbeta_accuracy	FN
0	KNN	0.570513	0.627737	0.684713	35
1	Support vectors machine (SVM)	0.711538	0.775510	0.805085	21
2	Decision Tree	0.705128	0.800000	0.803109	16
3	Logistic Regression	0.743590	0.771429	0.828221	24
4	Random Forest	0.724359	0.812903	0.816062	15

Рис. 19: Результаты обучения для данных после балансировки SMOTE

Лучшими моделями оказались «Decision Tree» и «Random Forest». В сравнении с несбалансированными данными наблюдается высокая точность по метрике F_β . На рисунках ниже приведены результаты, полученные с использованием методом SHAP и LIME.

Decision Tree LIME explanation	
Признак	Вклад
Число фракций СРТ <= 0.00	-0.3959
Операция <= 0.00	-0.1365
Число очагов в ГМ > 0.10	0.1029
0.00 < Развитие МГМ - Постановка онкологического диагноза <= 0.09	-0.0687
1-ая СРТ - Развитие МГМ > 0.07	-0.0672
ОВГМ > 0.00	0.0651
1-ая СРТ - ДР <= -0.11	0.0512
-0.17 < Индекс Карновского <= 0.00	-0.0410
0.00 < РМЖ <= 1.00	0.0270
Таргентная терапия <= 0.00	-0.0260

Рис. 20: LIME интерпретация для Decision Tree

```

=====
Random Forest LIME explanation
-----
Feature                                Weight
-----
Число фракций СРТ > 0.00              0.3552
Число очагов в ГМ > 0.12              0.1226
Операция <= 0.00                      -0.0697
ОВГМ <= 0.00                         -0.0616
1-ая СРТ - Развитие МГМ <= -0.01      0.0588
Развитие МГМ - Постановка онкологического диагноза <= -0.05  0.0517
-0.17 < Индекс Карновского <= 0.00   -0.0485
Меланома <= 0.00                     -0.0300
0.01 < 1-ая СРТ - ДР <= 0.13         -0.0252
0.01 < Суммарный объем очагов <= 0.14 -0.0202
=====

```

Рис. 21: LIME интерпретация для Random Forest




Рис. 22: SHAP интерпретация для Decision Tree




Рис. 23: SHAP интерпретация для Random Forest

Заметна значительная важность таких признаков, как «Число фракций СРТ», «Число очагов в ГМ» и «Операция». Важно отметить, что в отличие от алгоритма «Decision Tree» модель «Random Forest» учитывает виды онкологий и лечение пациентов. Таким образом, проведение химиотерапии увеличивает шанс на положительный прогноз, то есть наблюдается достаточно сильная корреляция признака «Химиотерапия» и вероятности прогрессии. Для алгоритма «Decision Tree» индекс Карновского имеет достаточно большое значение. Здесь также наблюдается прямая зависимость с вероятностью появления метастазов.

Заключение

Для проведения исследования были подробно рассмотрены используемые алгоритмы машинного обучения и метрики для оценки точности алгоритмов. Научились работать с необработанными данными. Были изучены методы интерпретации полученных результатов, такие как LIME и SHAP.

В дальнейшем планируется исследование других алгоритмов с более подробным анализом. Также представляет интерес увеличение имеющейся выборки пациентов и сравнение полученных результатов с текущими.

Список литературы

- [1] Brain metastasis [Electronic resource] // Wikipedia. – URL: https://en.wikipedia.org/wiki/Brain_metastasis
- [2] Егор Захаренко. Метод k-ближайших соседей (knn). Принцип работы, разновидности и реализация с нуля на python. Habr, 2024. URL: <https://habr.com/ru/articles/801885/>
- [3] Yuri Kashnitsky. Открытый курс машинного обучения. Тема 3. Классификация, деревья решений и метод ближайших соседей. Habr, 2017. URL: <https://habr.com/ru/companies/ods/articles/322534/>
- [4] Краткий обзор алгоритма машинного обучения Метод Опорных Векторов (SVM). Habr, 2018. URL: <https://habr.com/ru/articles/428503/>
- [5] Хуснутдинов Алмаз. Машинное обучение: Логистическая регрессия. Теория и реализация. С нуля. Habr, 2024. URL: <https://habr.com/ru/articles/864890/>
- [6] Random Forest Algorithm in Machine Learning. URL: <https://www.geeksforgeeks.org/random-forest-algorithm-in-machine-learning/>
- [7] Mia Hubert and Ellen Vandervieren. An adjusted boxplot for skewed distributions. Computational statistics & data analysis, 52(12):5186–5201, 2008.
- [8] Chawla N.V. et al. "SMOTE: Synthetic Minority Over-sampling Technique" // Journal of Artificial Intelligence Research. - 2002. - Vol. 16. - P. 321-357.
- [9] Lundberg S. M., Lee S. I. A unified approach to interpreting model predictions //Advances in neural information processing systems. – 2017. – Т. 30.
- [10] С.М. Банов. ОПТИМИЗАЦИЯ РАДИОХИРУРГИЧЕСКОГО ЛЕЧЕНИЯ ПАЦИЕНТОВ С МЕТАСТАТИЧЕСКИМ ПОРАЖЕНИЕМ ГОЛОВНОГО МОЗГА, 2020.